EJ7:

En este ejercicio tengo que relacionar la información de sentimiento proporcionada por un experto con los datos financieros obtenidos de Yahoo Finance.

El principal problema para relacionar la información de sentimiento con los datos de Yahoo Finance es que ambas fuentes usan identificadores diferentes: Yahoo Finance identifica las empresas usando su ticker, mientras que los datos del experto están organizados por sectores, por lo que no es posible relacionarlas directamente sin añadir información adicional.

Para resolver este problema investigué los datos disponibles mediante la librería yfinance, que permite consultar información adicional sobre las empresas. Usé el atributo sector para conocer a qué sector pertenecía cada empresa del IBEX 35.

Construí una dimensión que relaciona los 35 tickers con sus respectivos sectores económicos. Los datos originales se guardaron en Bronze y se normalizaron en Silver, convirtiendo los nombres a minúsculas para facilitar las uniones.

La solución consiste en relacionar las 3 fuentes de información con dos operaciones:

- Unir las cotizaciones del IBEX con la dimensión de los sectores usando la columna Ticker.
- Incorporar los datos de sentimiento usando las columnas Fecha y Sector.

Así cada cotización puede tener asociado el sentimiento asignado a su sector en esa fecha. Con esto puedo analizar si existe alguna relación entre el sentimiento y la evolución de los precios de las acciones.

La ventaja es que aprovecho la información adicional de Yahoo Finance sin modificar los datos originales del experto y mantengo una estructura por capas.

EJ8:

Para realizar la transformación usé PySpark , implementando la función limpiar_sentimiento() en el archivo ingesta.py. Esta función aplica las siguientes operaciones:

- Convertí la columna Fecha a tipo date para poder relacionarla con las fechas de las cotizaciones.
- Eliminé espacios innecesarios al principio y al final de los nombres de los sectores y puse todos en minúsculas. Así evito problemas de correspondencia entre nombres.
- Convertí la columna Sentimiento al tipo double y sustituí las comas decimales por puntos. Así los valores se pueden usar directamente en operaciones.
- Eliminé los valores nulos.

- Eliminé valores duplicados de las columnas Fecha y Sector para que cada combinación de fecha y sector aparezca solo una vez

Gracias a todo este proceso de limpieza pasé de 29304 registros en Bronze a 14652 en Silver.

EJ11:

Para identificar los registros que no se pudieron relacionar durante la integración de las fuentes, realicé un left_anti join entre las cotizaciones del IBEX y los datos de sentimiento, usando las columnas Fecha y Sector.

En total había 910 cotizaciones sin correspondencia, pertenecientes a 26 fechas comprendidas entre el 1 de octubre y el 5 de noviembre de 2026. Esto indica una diferencia en la cobertura temporal de las dos fuentes de datos.

También realicé el anti-join inverso para identificar los registros de sentimiento que no tenían cotizaciones asociadas. En este caso encontré 9.042 registros. Esto se debe a que los datos de sentimiento incluyen fechas anteriores al período de cotizaciones del IBEX.

Para resolver esto, usé un left join en la construcción de la capa Gold, conservando todas las cotizaciones financieras y dejando el campo Sentimiento con valor nulo cuando no existe información correspondiente.

Así no se eliminan cotizaciones válidas ni hay que introducir valores de sentimiento artificiales. De esta forma la capa Gold conserva sus 18760 registros, de los cuales 17.850 tienen información de sentimiento asociada.

EJ13:

En este ejercicio exporté la capa Gold a formato Parquet utilizando PySpark, conservando los 18.760 registros y las columnas añadidas durante los ejercicios anteriores. Para organizar la información también investigué el modelo en estrella, que consiste en tener una tabla de hechos con los datos principales relacionada con varias tablas de dimensiones. Esta estructura permite organizar mejor la información y facilita los análisis. En mi caso, he exportado una tabla Gold integrada que contiene los datos financieros, el sector y el sentimiento, manteniendo también la versión original en Delta Lake.